
Optimización de Planogramas en Tiendas OXXO

Entregable 3: Experimentación y Resultados

Reto MA2008B – Optimización No Lineal

Equipo

Daniel Eugenio González Limas	A01285898
Sebastián Zaragoza Díaz	A01286211
Cedrick Patricio Treviño Ortiz	A01198868
Lillianne Sepúlveda Cuevas	A00839109
Juan Fernando González Cervantes	A01571586
Javier Rojas Orrante	A01352213

IDM, 6to Semestre
Instituto Tecnológico y de Estudios Superiores de Monterrey

github.com/DaniellaBanda/RETO_OXXO_OPTINL

Abstract

Este trabajo aborda el problema de *planogramación* de tiendas OXXO: dada la asignación de productos y sus frentes (decidida en etapas previas del proceso comercial), se determina la ubicación óptima de cada producto dentro de un mueble de cuarto frío. Se presenta un algoritmo genético (en dos variantes, no extendida y extendida) y se compara contra un modelo no lineal tipo *random-key* resuelto por **evolución diferencial** (*Differential Evolution*), sobre cuatro formatos de planograma reconstruidos del histórico. La función objetivo, no lineal por su término de varianza, maximiza aprovechamiento de espacio, coherencia de tamaño y agrupación de marca. El algoritmo genético supera tanto al acomodo experto histórico como al modelo no lineal en los cuatro formatos, con aprovechamiento de espacio entre 90.9 % y 95.7 %.

Contents

1	Introducción y contexto	2
2	Modelo matemático	2
2.1	Conjuntos, parámetros y variables	2
2.2	Función objetivo (no lineal)	2
2.3	Método heurístico: algoritmo genético	3
2.4	Modelo no lineal de comparación (<i>random-key</i>)	3
3	Procesamiento de datos y valores esperados	3
4	Tamaño del problema	4
5	Experimentación y resultados	4
5.1	Entorno de cómputo	5
5.2	Supuestos	5
5.3	Configuración de los algoritmos	5
5.4	Comparación por formato: Histórico vs. GA vs. NLP	5
5.5	Pesos obtenidos por simulación	6
5.6	Valor esperado de la ubicación del producto	7
5.7	Planograma reconstruido	7
5.8	Convergencia y comparación por criterio	9
6	Conclusiones	9
	Anexo: código	10
	Bibliografía	10

1 Introducción y contexto

El proceso de surtido de OXXO consta de cuatro etapas: segmentación de la tienda, asignación de espacio por categoría, definición de variedad y **planogramación**. Este trabajo se ubica en la última: el tamaño del mueble y la lista de productos con sus frentes *ya están decididos*, y solo resta ubicar cada producto en su charola y posición. Por ello el modelo no maximiza ventas (decididas aguas arriba) sino la **calidad del acomodo**, medida como una combinación de aprovechamiento de espacio, coherencia de tamaño y agrupación de marca.

El objetivo del entregable es **experimentar** con el modelo: resolver el problema con un algoritmo genético (GA), contrastarlo con un modelo de optimización no lineal sobre las mismas instancias, y validar los resultados contra el acomodo histórico real de OXXO.

2 Modelo matemático

2.1 Conjuntos, parámetros y variables

Conjuntos: $P = \{1, \dots, N\}$ bloques-producto a colocar; $S = \{1, \dots, M\}$ charolas del mueble (con $M = 6 \cdot \text{TAMAÑO}$); B marcas, con $b_j \in B$ la marca del producto j .

Parámetros: $a_j = \text{ANCHO}_j \times \text{frentes}_j$ (ancho del bloque, cm), h_j (alto, cm), $W = 55$ cm (ancho útil de charola en cuarto frío), $\text{SEP} = 0.5$ cm (separador entre productos), w_1, w_2, w_3 (pesos), ρ (penalización por charola excedente) y $P(\text{charola} \mid j)$ (distribución histórica de ubicación).

Variables: $x_{ij} \in \{0, 1\}$ (bloque j en charola i) y $p_{ij} \in \mathbb{Z}_{\geq 0}$ (posición dentro de la charola). El modelo no lineal usa además $y_j \in [0, 1]$, una llave continua (*random-key*) que induce el orden de colocación.

2.2 Función objetivo (no lineal)

$$\max Z = w_1 U - w_2 C_{\text{tam}} + w_3 B_{\text{marca}} - \rho \cdot \max(0, M_{\text{usadas}} - M) \quad (1)$$

donde cada criterio se define a continuación (sobre S' , el conjunto de charolas utilizadas, y n_i el número de bloques en la charola i).

Aprovechamiento de espacio (U): ocupación promedio del ancho de las charolas usadas (se desea alta):

$$U = \frac{1}{|S'|} \sum_{i \in S'} \frac{1}{W} \sum_{j \in P} a_j x_{ij}. \quad (2)$$

Incoherencia de tamaño (C_{tam}): promedio de la desviación estándar de la altura dentro de cada charola (se penaliza; es el término **no lineal** por involucrar varianzas):

$$C_{\text{tam}} = \frac{1}{|S'|} \sum_{i \in S'} \sqrt{\frac{1}{n_i} \sum_{j \in P} x_{ij} (h_j - \bar{h}_i)^2}, \quad \bar{h}_i = \frac{1}{n_i} \sum_{j \in P} x_{ij} h_j. \quad (3)$$

Agrupación de marca (B_{marca}): fracción de pares de productos contiguos en la misma charola que comparten marca (se premia):

$$B_{\text{marca}} = \frac{\#\{\text{vecinos contiguos con } b_j = b_k\}}{\#\{\text{vecinos contiguos}\}}. \quad (4)$$

La restricción dura es la capacidad de ancho con separadores:

$$\sum_{j \in P} a_j x_{ij} + \text{SEP} (n_i - 1) \leq W \quad \forall i \in S, \quad (5)$$

El modelo extendido (GA2) añade un término $+w_4 L$ que premia colocar cada producto cerca de su charola esperada histórica.

2.3 Método heurístico: algoritmo genético

Cada individuo es una **permutación** de los N bloques. Se decodifica con un esquema *first-fit*: se recorren los bloques en el orden de la permutación y se colocan en la charola actual mientras quepan (Ec. (5)); al no caber, se abre la siguiente. Así toda permutación es factible en ancho por construcción y solo se penaliza el exceso de charolas.

Algorithm 1 Algoritmo genético para el acomodo de planograma

```

1: Inicializar población (50 % sembrada por altura con ruido, 50 % aleatoria)
2: for cada generación do
3:   Evaluar el fitness de cada individuo (Ec. (1))
4:   Conservar la élite
5:   while población incompleta do
6:     padres  $\leftarrow$  selección por torneo ( $k = 3$ )
7:     hijo  $\leftarrow$  OX(padres); hijo  $\leftarrow$  mutar(hijo)
8:     agregar hijo
9:   end while
10: end for
11: return mejor individuo encontrado

```

2.4 Modelo no lineal de comparación (*random-key*)

Para contrastar el algoritmo genético se implementó un modelo de optimización no lineal con codificación *random-key*: cada bloque j tiene una variable continua $y_j \in [0, 1]$; al ordenar los valores y_j se obtiene una permutación que el *mismo* decodificador first-fit del GA convierte en charolas. La función objetivo es la misma de la Ec. (1), por lo que la comparación es directa y aísla el *método de búsqueda*. Como la función $Z(y)$ no es suave ni convexa (por la desviación estándar de alturas y las adyacencias de marca), se resolvió con **evolución diferencial** (*Differential Evolution*, `scipy.optimize`), un optimizador global sin derivadas que opera sobre el vector continuo de llaves.

3 Procesamiento de datos y valores esperados

El socio formador proporcionó un dataset histórico de $\approx 497k$ filas de planogramas de *Refrescos* en cuarto frío, que agrega múltiples tiendas. El preprocesamiento (`preprocessing/pipeline_.py`) consta de cuatro pasos.

1. Clave de planograma.

Se agrupa por SEGMENTO + MUEBLE + TAMAÑO + PLANOGRUPO. Las direcciones DI/ID son el mismo diseño espejado, por lo que se reconstruye desde la dirección dominante.

2. Reconstrucción por bloques-producto.

El dataset no contiene ID de tienda: cada posición está observada ~ 95 veces (tiendas apiladas). Cada UBICACION_BANDEJA es un *frente*, no un producto. Por cada (charola, frente) se toma el UPC modal del histórico y se colapsan frentes consecutivos del mismo producto en bloques (frentes = número de bandejas, ancho = ANCHO $\times$ frentes). Así se obtiene un planograma canónico realista en lugar del universo agregado del formato.

3. Distribución y valor esperado de ubicación.

Cada producto no tiene una charola fija, sino una **distribución de probabilidad** $P(\text{charola} |$

producto), estimada contando en cuántas tiendas apareció en cada nivel. Su media es el **valor esperado de ubicación** $E[\text{charola}]$ (Sección 5.6); es el insumo del término w_4 de GA2.

4. Pesos por simulación.

En lugar de fijar w_1, w_2, w_3 a mano, se estiman por simulación: en cada uno de 1000 escenarios se muestrea un UPC por frente según $P(\text{UPC} \mid \text{posición})$, se arma un planograma plausible y se miden los tres criterios. El valor esperado y la desviación de cada criterio determinan los pesos mediante $w_k \propto E[\text{criterio}_k]/\sigma[\text{criterio}_k]$ (relación señal/ruido), normalizados a escala 3.

Artefactos y validación. El pipeline produce por formato tres archivos en `data/`: `oxxo_instance_*.csv` (bloques con dimensiones, frentes, marca y $E[\text{charola}]$), `oxxo_locdist_*.json` (distribución de charola por producto) y `oxxo_weights_*.json` (pesos simulados con sus desviaciones y un campo de validación). El GA y el modelo no lineal consumen exactamente la misma instancia. Se validó automáticamente que cada planograma tuviera un número de productos realista, charolas iguales al nominal del formato, ancho por charola ≤ 55 cm (con tolerancia) y un solo producto por posición: **132 de 132 planogramas** pasaron la validación.

4 Tamaño del problema

El problema se representa como un **grafo bipartito de asignación** producto–charola: hay un nodo por cada bloque–producto y un nodo por cada charola, de modo que $|V| = |P| + |S|$; cada posible asignación de un producto a una charola es un arco, $|A| = |P| \cdot |S|$. La formulación *random-key* optimiza $|P|$ variables continuas (una llave por producto); su equivalente discreto tendría una variable binaria x_{ij} por arco ($|P| \cdot |S|$). Los parámetros son a_j, h_j, b_j por bloque más los globales $W, \text{SEP}, w_1, w_2, w_3, \rho$, esto es $3|P| + 6$.

Formato	Nodos	Arcos	Var. NLP	Var. grafo	Parám.
	$ P + S $	$ P \cdot S $	$ P $	$ P \cdot S $	$3 P + 6$
SIN_CFC_1.0 (27p/6c)	33	162	27	162	87
OFC_CF_2.0 (67p/12c)	79	804	67	804	207
BCO_CF_4.0 (101p/24c)	125	2424	101	2424	309
OFC_CF_5.5 (156p/32c)	188	4992	156	4992	474

Table 1. Dimensiones del problema por formato.

5 Experimentación y resultados

5.1 Entorno de cómputo

Componente	Especificación
Modelo de la PC	MacBook Air (Apple Silicon)
Sistema operativo	macOS Tahoe 26.5
Memoria RAM	16 GB
Software	Python 3.13.13 (un solo hilo)
Librerías	numpy 2.4.6, pandas 3.0.3, scipy 1.17.1, Pillow 12.2.0, matplotlib 3.10.9
Modelo no lineal	Random-key + Differential Evolution (<code>scipy.optimize</code>)

Table 2. Entorno de cómputo utilizado.

5.2 Supuestos

- Los frentes son un dato dado por el socio; no se optimizan.
- Ancho útil de charola = 55 cm (cuarto frío); separador de 0.5 cm solo entre productos, no en los bordes.
- El planograma se reconstruye con el UPC modal por posición; es una aproximación estadística (ver limitaciones).
- Las direcciones DI/ID se tratan como espejo de un mismo diseño.

5.3 Configuración de los algoritmos

Algoritmo genético		Modelo no lineal (random-key)	
Población	150	Representación	$y_j \in [0, 1]$ continua
Generaciones	400	Decodificador	First-fit (igual al GA)
Elitismo	8	Búsqueda	Evolución diferencial (DE)
Selección	Torneo, $k = 3$	Estrategia	<code>best1bin</code> , recomb. 0.7
Cruce	OX	Población DE	$8 \cdot N$
Mutación	0.2	Evaluaciones	hasta $\sim 309k$
Semilla	42	Semilla	7

Table 3. Configuración del GA y del modelo no lineal. Ambos optimizan la misma función objetivo y usan el mismo decodificador, por lo que sus fitness son directamente comparables.

5.4 Comparación por formato: Histórico vs. GA vs. NLP

La Tabla 4 resume el desempeño de los tres enfoques en los cuatro formatos, sobre la misma instancia y la misma función objetivo.

Formato	Método	Fit.	Aprov.%	Desp.%	Incoh.	Marca%	Char.	t(s)
BCO_CF_4.0 101p/24c	Histórico	2.349	88.5	11.5	1.72	55.8	24	—
	GA	2.442	92.4	7.6	2.24	59.0	23	11.9
	NLP rnd-key	2.323	92.4	7.6	5.01	25.6	23	31.2
SIN_CFC_1.0 27p/6c	Histórico	2.092	75.6	24.4	1.00	57.1	6	—
	GA	2.526	90.9	9.1	3.42	81.8	5	3.9
	NLP rnd-key	2.476	90.9	9.1	5.96	77.3	5	2.1
OFC_CF_2.0 67p/12c	Histórico	2.418	90.6	9.4	1.82	56.4	12	—
	GA	2.462	90.6	9.4	1.25	72.7	12	7.7
	NLP rnd-key	2.328	90.6	9.4	4.57	40.0	12	18.4
OFC_CF_5.5 156p/32c	Histórico	2.119	80.6	19.4	1.54	51.6	32	—
	GA	2.502	95.7	4.3	1.61	51.2	27	15.8
	NLP rnd-key	2.329	95.7	4.3	5.80	17.1	27	80.9

Table 4. Comparación de los tres enfoques por formato (Refrescos, cuarto frío). El GA obtiene el mayor fitness en los cuatro casos. Incoh. = desviación estándar media de altura por charola (cm); Marca = % de adyacencias de la misma marca; Char. = charolas usadas (sin sobrecupo en ningún caso).

Lectura. El algoritmo genético **supera tanto al acomodo experto histórico como al modelo no lineal en los cuatro formatos** ($\text{Fit}_{\text{GA}} > \text{Fit}_{\text{Hist}} > \text{Fit}_{\text{NLP}}$). El modelo no lineal *igual* el aprovechamiento de espacio (mismo % y mismas charolas usadas, pues comparte el decodificador first-fit), pero **pierde en coherencia de tamaño** (incoherencia ~ 5 cm frente a ~ 1.6 – 2.2 del GA) y en agrupación de marca. La razón es que el *argsort* de las llaves continuas no agrupa por altura ni por marca, mientras que los operadores de permutación del GA, junto con la siembra inicial por altura, sí lo hacen. Además, el modelo no lineal **no es más barato**: consume más evaluaciones (hasta $\sim 309\text{k}$) y más tiempo (hasta 80.9 s) y aun así queda por debajo. Esto valida empíricamente la elección del GA argumentada en el Entregable 2 (problema NP-duro y función no lineal).

Diferencia porcentual. El GA mejora sobre el acomodo histórico entre 1.8% (OFC_CF_2.0) y 20.7% (SIN_CFC_1.0), tomando el histórico como base. Respecto al modelo no lineal, el GA lo supera entre 2.0% (SIN_CFC_1.0) y 7.4% (OFC_CF_5.5), tomando el NLP como base. La ventaja relativa del GA es mayor en formatos donde un buen ordenamiento por altura tiene más impacto.

5.5 Pesos obtenidos por simulación

Formato	w_1	w_2	w_3	$E_{\text{util}} \pm \sigma$	$E_{\text{incoh}} \pm \sigma$	$E_{\text{block}} \pm \sigma$
SIN_CFC_1.0	2.549	0.139	0.312	0.760 ± 0.003	1.241 ± 0.086	0.578 ± 0.018
OFC_CF_2.0	2.593	0.215	0.192	0.913 ± 0.007	1.924 ± 0.185	0.482 ± 0.052
BCO_CF_4.0	2.601	0.241	0.158	0.894 ± 0.005	1.856 ± 0.122	0.426 ± 0.043
OFC_CF_5.5	2.552	0.252	0.197	0.810 ± 0.005	1.626 ± 0.101	0.440 ± 0.035

Table 5. Pesos de la función objetivo por valor esperado ($n_{\text{sim}} = 1000$), $w_k \propto E[\text{criterio}_k]/\sigma[\text{criterio}_k]$ normalizado a escala 3.

Interpretación. El peso w_1 (aprovechamiento) domina porque es el criterio que el histórico aplica de forma más consistente (desviación entre escenarios muy baja, $\sigma \approx 0.005$, alta señal/ruido). La coherencia de tamaño y la agrupación de marca pesan menos porque varían más entre tiendas.

5.6 Valor esperado de la ubicación del producto

Cada producto lleva una distribución de probabilidad de charola derivada del histórico. Los tres tamaños de Coca-Cola ilustran una regla física que emerge de los datos: a menor tamaño del envase, mayor el valor esperado de charola (producto más arriba).

Producto	Distribución (principales)	de	charola	$E[\text{ch}]_{\text{norm}}$	$E[\text{ch}]$
Coca 3 L	ch1: 32.7%, ch19: 13.1%	31.3%, ch7/13:		0.414	9.9
Coca 600 ml	ch10: 22.3%, ch16: 12.0%, ch3: 11.7%	21.5%, ch4:		0.529	12.7
Coca 355 ml (lata)	ch6: 47.3%, ch24: 4.0%	44.6%, ch12/18:		0.615	14.8

Table 6. Distribuciones de ubicación en BC0_CF_4.0_Refrescos ($M = 24$ charolas).

Nota. Las charolas aparecen en pares (ch6/ch24, ch1/ch19), lo que sugiere que el índice corre por columna y que cada par es el mismo nivel físico en distintas puertas del cuarto frío. Por ello el valor esperado del envase de 3 L queda en la zona media (0.41) pese a ubicarse físicamente abajo: promedia dos columnas del mismo nivel. La tendencia monótona (envase grande $\rightarrow$ nivel bajo, lata $\rightarrow$ nivel alto) se conserva.

5.7 Planograma reconstruido

La Figura 1 muestra el acomodo generado por el GA charola por charola. Se observa la estructura típica: Coca-Cola domina los niveles superiores, Pepsi los intermedios y las marcas menores (Peñafiel, Topo Chico, Squirt, Dr Pepper) los inferiores, con las charolas casi llenas hasta el límite de 55 cm.

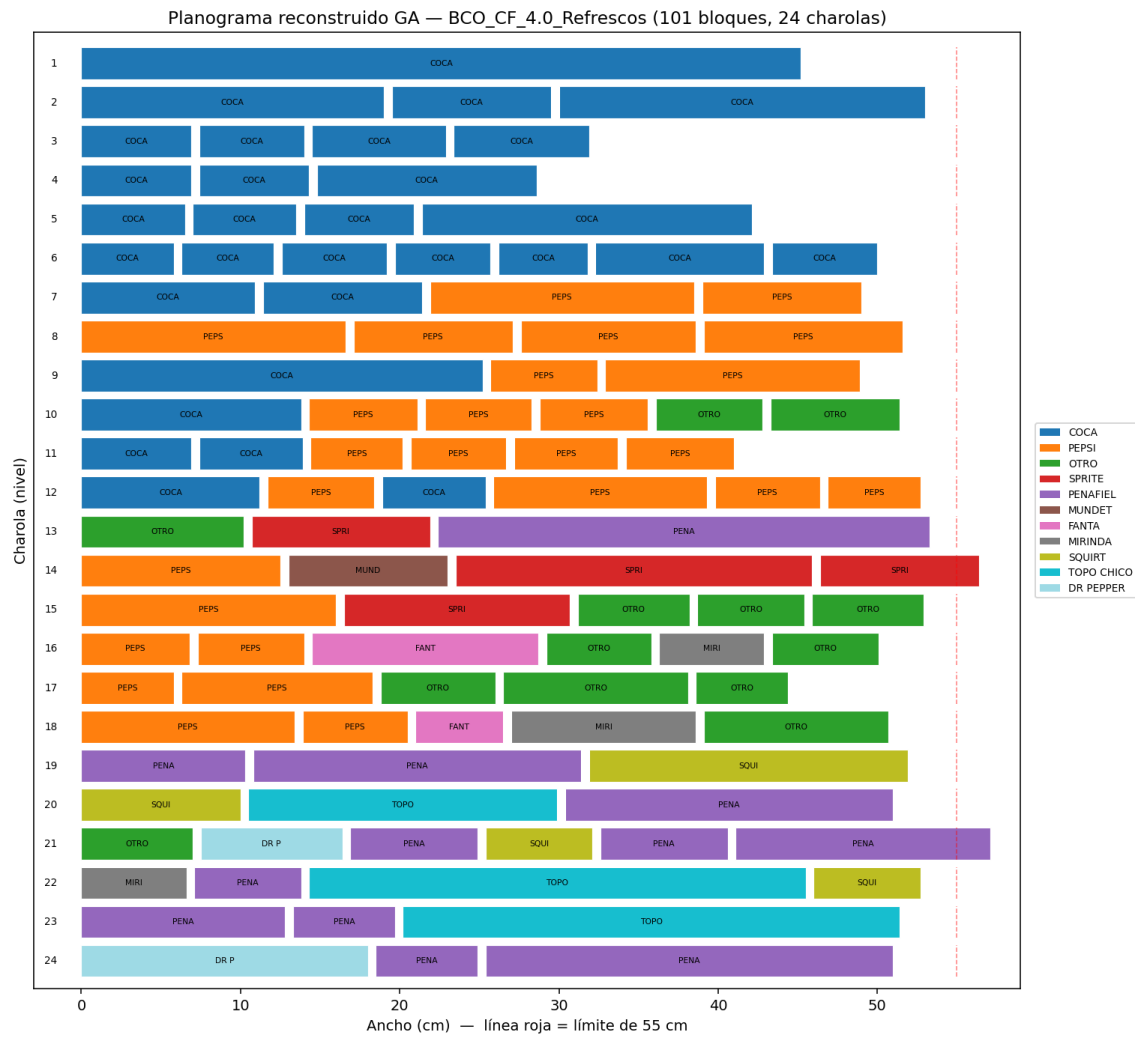


Figure 1. Planograma reconstruido por el GA para BCO_CF_4.0_Refrescos (101 bloques, 24 charolas). La línea roja marca el límite de 55 cm.

5.8 Convergencia y comparación por criterio




Figure 2. Convergencia del fitness de las dos variantes del algoritmo genético en BCO_CF_4.0_Refrescos.




Figure 3. Izquierda: el GA converge a un mejor fitness que la evolución diferencial sobre las llaves continuas. Derecha: ambos igualan el aprovechamiento, pero el GA mantiene mucho mejor la agrupación de marca y la coherencia de tamaño.

6 Conclusiones

- El modelo de planogramación produce acomodos válidos en los cuatro formatos, con aprovechamiento de 90.9 % a 95.7 %, respetando las restricciones físicas y el espaciado de 0.5 cm.
- **El algoritmo genético supera al acomodo experto histórico y al modelo no lineal en los cuatro formatos.** El NLP iguala el aprovechamiento pero pierde en coherencia de tamaño y agrupación de marca, y además consume más tiempo y evaluaciones. Esto valida empíricamente la elección del GA.
- La reconstrucción por bloques-producto permitió trabajar con planogramas realistas (27 a 156 bloques) en lugar del universo agregado del formato.
- Los valores esperados de ubicación y los pesos de la función objetivo se derivaron de los datos por simulación, no se fijaron a mano.

- El modelo es parametrizable: cambiar W de 55 a 91 cm lo extiende a góndola central sin reformular.
- **Limitación:** el planograma modal es una aproximación estadística; unas pocas charolas exceden ligeramente 55 cm (máx 57.1 en BCO_CF_4.0, 2 de 24), artefacto de mezclar modas de distintas tiendas.
- **Factibilidad de la extensión:** GA2 está preparado para incorporar parámetros reales (demanda, margen) cuando el socio los proporcione; actualmente se usan valores *placeholder*.

Anexo: código

Código disponible en el repositorio [DaniellLaBanda/RETO_OXXO_OPTINL](#). Archivos principales:

- `preprocessing/pipeline_.py` — reconstrucción de planogramas y simulación de pesos.
- `genetic_algorithm/ga1.py` y `ga2.py` — modelos no extendido y extendido.
- `mathematical_model/nlp_model.py` — modelo no lineal random-key y comparación contra el GA.
- `mathematical_model/math_model.py` — generación de tablas y figuras de resultados.

Bibliografía

References

- [1] Hübner, A. y Schaal, K. (2016). A shelf-space optimization model when demand is stochastic and space-elastic. *Omega*, 68, 139–154.
- [2] Czerniachowska, K. et al. (2021). Genetic algorithm for the retailers' shelf space allocation profit maximization problem. *Applied Sciences*, 11(14), 6401.
- [3] Gencosman, B. C. y Begen, M. A. (2021). Exact optimization and decomposition approaches for shelf space allocation. *European Journal of Operational Research*, 299(2), 432–447.
- [4] Storn, R. y Price, K. (1997). Differential Evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4), 341–359.
- [5] Isa, F. M. et al. (2024). Shelf space allocation problem (SSAP) in the retail industry: A systematic literature review.